

逻辑回归算法

1.逻辑斯蒂分布（logistic distribution）

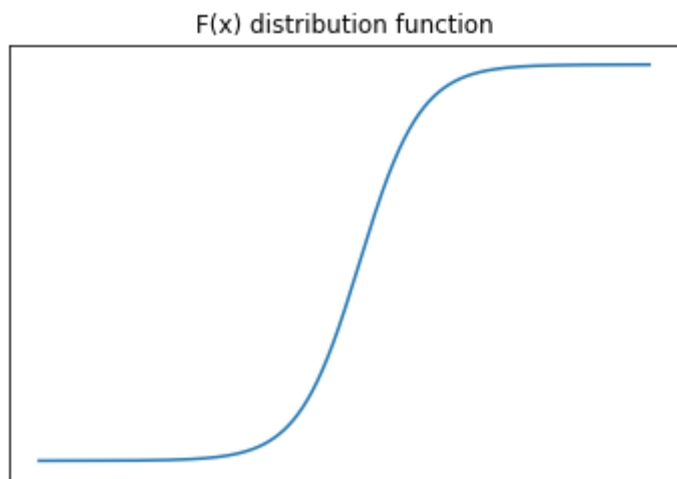
假设 X 是连续随机变量， X 如果满足以下条件：

$$F(x) = P(X \leq x) = \frac{1}{1 + e^{\frac{-(x-\mu)}{\gamma}}}$$

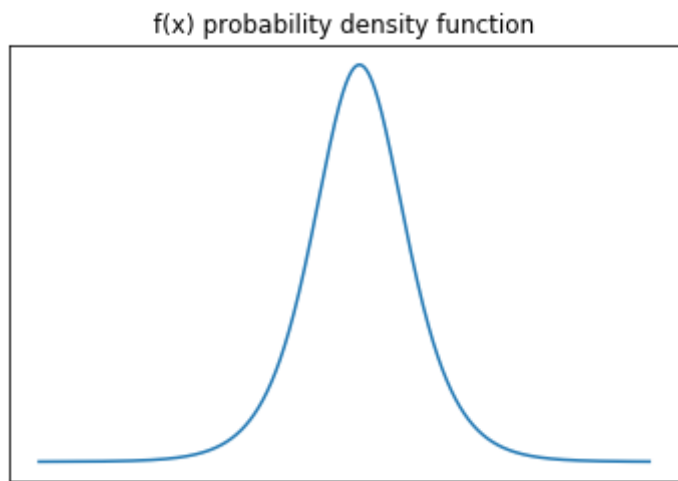
$$f(x) = F'(x) = \frac{e^{\frac{-(x-\mu)}{\gamma}}}{\gamma(1 + e^{\frac{-(x-\mu)}{\gamma}})^2}$$

则 X 服从逻辑斯蒂分布，其中 μ 为位置参数， $\gamma > 0$ 为形状参数。

其中概率分布函数 $F(x)$ 形状如下：



概率密度函数形状如下：



2. 二项逻辑斯蒂回归模型

一般来说，回归模型是对连续值计算得到最近似的拟合函数。但是逻辑斯蒂回归模型不一样，虽然叫回归模型，但是实际上是计算分类的模型，用于计算二分类。

二项逻辑斯蒂回归模型是如下的概率分布：

$$P(Y = 1|x) = \frac{\exp(w \cdot x + b)}{1 + \exp(w \cdot x + b)}$$

$$P(Y = 0|x) = \frac{1}{1 + \exp(w \cdot x + b)}$$

其中 $x \in R^n$, 即为 n 维实数向量； $Y \subset \{0, 1\}$ 是输出，即为类别； $w \in R^n$ 和 $b \in R$ 分别为权重和偏置， $w \cdot x$ 是两个向量的内积。

3. 模型参数的计算

回顾上一章节的课程，SGD(批量梯度下降)算法，需要有很多的样本去计算参数。这里也是一样，对于给定的训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 其中 $x_i \in R^n, y_i \in \{0, 1\}$ 。

在这里计算参数 w 和 b 的时候，需要用到极大似然估计法计算。至于为什么要用极大似然估计法计算，作为一个思考题，让大家去思考。

我们先设：

$$P(y_i = 1|x_i) = \pi(x_i), P(y_i = 0|x_i) = 1 - \pi(x_i)$$

合起来可以写为：

$$P(y_i|x_i;w) = \pi(x_i)^{y_i} [1 - \pi(x_i)]^{1-y_i}$$

似然函数为:

$$\prod_{i=1}^N [\pi(x_i)]^{y_i} [1 - \pi(x_i)]^{1-y_i}$$

此函数过于复杂，由于对数函数与原函数的单调性一致，因此这里一个技巧就是将上式取对数。则有：

$$L(w) = \frac{1}{N} \sum_{i=1}^N [y_i \log(\pi(x_i)) + (1 - y_i) \log(1 - \pi(x_i))]$$

其中 $\frac{1}{N}$ 是求平均的系数，不影响函数的单调性。求上式的最大值，即是求 $-L(w)$ 的最小值。

于是我们得到的目标函数就为 $-L(w) = J(w)$, 对上述式子进行梯度下降算法计算得到参数 \tilde{w}, \tilde{b} , 就有:

$$P(y_i = 1|x_i) = \frac{\exp(\tilde{w} \cdot x_i + \tilde{b})}{1 + \exp(\tilde{w} \cdot x_i + \tilde{b})}$$

$$P(y_i = 0|x_i) = \frac{1}{1 + \exp(\tilde{w} \cdot x_i + \tilde{b})}$$

我们可以得到每个样本 x_i 为0和1的概率，如果为1的概率大，那么 x_i 就被归结到1这个类别，否则就归结到0这个类别，0和1分别为类别的编码号。比如{好西瓜=1，坏西瓜=0}，或者{好房子=1，坏房子=0}。

4. 随机梯度下降计算最佳参数

对 $J(w)$ 求其梯度函数为:

$$\frac{\partial J(w)}{\partial(w)} = -\frac{1}{N} \sum_{i=1}^N [y_i \frac{\pi(x_i)'}{\pi(x_i)} + (1 - y_i) \frac{-\pi(x_i)'}{1 - \pi(x_i)}]$$

我们知道:

$$\pi(x_i) = \frac{\exp(w \cdot x_i + b)}{1 + \exp(w \cdot x_i + b)}$$

令：

$$z = w \cdot x_i + b$$

所以：

$$\frac{\partial(z)}{\partial(w)} = x_i$$

则上式变为：

$$\frac{\partial J(w)}{\partial(w)} = \sum_{i=1}^N \left[y_i \frac{\pi(x_i)'}{\pi(x_i)} + (1 - y_i) \frac{-\pi(x_i)'}{1 - \pi(x_i)} \right] = \sum_{i=1}^N \left[y_i \frac{\pi(z_i)'}{\pi(z_i)} + (1 - y_i) \frac{-\pi(z_i)'}{1 - \pi(z_i)} \right] \frac{\partial(z)}{\partial(w)}$$

我们知道：

$$\pi(z)' = \pi(z)(1 - \pi(z))$$

代入上式得到：

$$\frac{\partial J(w)}{\partial(w)} = -\frac{1}{N} \sum_{i=1}^N [y_i - \pi(x_i)] x_i$$

于是得到梯度下降的公式为：

$$w := w - \alpha \frac{1}{N} \sum_{i=1}^N [\pi(x_i) - y_i] x_i$$

用矩阵表示即为：

$$w := w - \alpha \frac{1}{N} X^T [\pi(X) - Y]$$

5. 随机梯度下降构造逻辑斯蒂回归模型

利用上述的推导和上一章节对梯度下降算法的理解，我们可以尝试自己构造逻辑斯蒂回归模型了。这里我们有一份关于女性乳腺癌的数据集。具体可以查看示例代码。

